
Общие сведения

План



1. Линейная модель регрессии
2. Как линейные модели обучаются?
3. Линейная модель классификации


Что это такое?



x — баллы за экзамен по английскому 1

y — баллы за экзамен по английскому 2

x	y
1	5
3	11
9	35
10	33



Что это такое?




свободный член
(intercept)

случайная ошибка
(error)

$$y = w_0 + w_1 x + \epsilon$$

целевая переменная
(aka target)

независимая переменная
(slope, predictor)




А какая модель нам нужна?



$$MSE = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \rightarrow \min$$

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i| \rightarrow \min$$



Интерпретация коэффициентов



Зачем нужны линейные модели?

1. Предсказание интересующей нас величины
2. Оценка влияния различных факторов на нашу целевую переменную
3. Линейные модели очень легко использовать и интерпретировать
4. Линейные модели могут восстанавливать даже **нелинейные зависимости**




А если у нас много независимых переменных?




$$y = w_0 + w_1 x + w_2 z + \dots + w_n t + \epsilon$$

площадь	число комнат	школа близко	цена квартиры
50	2	нет	5000
1000	7	да	11000
30	1	нет	3500
100	4	нет	33333

Множественная линейная регрессия дает нам плоскость



Производные



$$\frac{dy}{dx} = \frac{y(x_0 + \Delta x) - y(x_0)}{\Delta x}$$

$y = f(x)$	$\frac{dy}{dx} = f'(x)$
k , any constant	0
x	1
x^2	$2x$
x^3	$3x^2$
x^n , any constant n	nx^{n-1}
e^x	e^x
e^{kx}	ke^{kx}
$\ln x = \log_e x$	$\frac{1}{x}$
$\sin x$	$\cos x$
$\sin kx$	$k \cos kx$
$\cos x$	$-\sin x$
$\cos kx$	$-k \sin kx$

Производные

$(0, 0, \frac{\pi}{2})$ - ответ

$$\varphi(x, y, z) = 2x^2 + 3y^2 - \sin z$$

$$\frac{\partial \varphi}{\partial x} = 4x$$


$$\frac{\partial \varphi}{\partial y} = 6y$$

$$\frac{\partial \varphi}{\partial z} = -\cos z$$

$$\begin{pmatrix} 4x \\ 6y \\ -\cos z \end{pmatrix} \text{ - градиент}$$

$$\varphi = \nabla_{xyz} \varphi$$

Производные (градиент)



- указывает в напр. наиб. роста ф-ции
- Антиградиент указ. в напр. ^{наим.} ~~наиб.~~ убыв.

Производные



Как оценивать коэффициенты модели?

$$X, y, w$$

$n \times 3$ $n \times 1$ 4×1

$$y = w_0 \cdot 1 + w_1 x_1 + \dots + w_3 x_3$$

$$\begin{bmatrix} 1 & x_1 & x_2 & x_3 \\ \vdots & & & \end{bmatrix}$$

$$n \times 4$$

$$y = X \cdot w$$

$n \times 1$ $n \times 4$ 4×1

$$\begin{bmatrix} 1 & x_1 & x_2 & x_3 \end{bmatrix} \begin{pmatrix} w_0 \\ w_1 \\ w_2 \\ w_3 \end{pmatrix} = \begin{pmatrix} 1 \cdot w_0 + x_1 w_1 + \dots + x_3 w_3 \end{pmatrix}$$

Как оценивать коэффициенты модели?

$$MSE = \frac{1}{N} (y - \overset{\text{matrix}}{X} \overset{\text{vector}}{w})^2 = \frac{1}{N} (y - Xw)^T (y - Xw)$$

$\begin{matrix} n \times 1 & n \times n & n \times 1 \end{matrix}$



$$\nabla_{\underset{4 \times 1}{w}} MSE = - \left[\frac{1}{N} \cdot 2 \cdot \underset{4 \times n}{X^T} (\underset{n \times 1}{y} - \underset{n \times 1}{Xw}) \right] = \frac{2}{N} \cdot X^T (Xw - y)$$

$$w_{(i+1)} = w_{(i)} - \underset{\substack{\uparrow \\ \text{eta - learning rate}}}{\eta} \nabla MSE(w_i)$$

$\begin{matrix} 4 \times 1 & 4 \times 1 \end{matrix}$

$$\eta: [0.001, 0.01]$$

Градиентный спуск



Формулы

$$y = w_0 + w_1 x + \epsilon$$

$$y = Xw$$

$$\frac{dLoss}{dw} = \nabla Loss = \underbrace{2}_{\sim} \underbrace{X^T}_{\sim} (Xw - y)$$

$$Loss = \underbrace{1}_{\sim} (y - Xw)^T (y - Xw)$$

$$w = (X^T X)^{-1} X^T y$$

Градиентный спуск



$$Loss = \frac{1}{N} (y - Xw)^T (y - Xw) \quad \frac{dLoss}{dw} = \nabla Loss = \frac{2}{N} X^T (Xw - y)$$

```
w = np.random.randn(m + 1)
Пока grad(Loss) != 0:
    w -= η * grad(Loss)
```

Отдых -> логистическая регрессия

Связь событий и признаков



В зависимости от предикторов события могут происходить чаще или реже – логика, совпадающая с логикой связи количественной переменной отклика с набором предикторов.

Например, по мере роста температуры воздуха летом чаще будут встречаться люди в шортах: событие “встретился человек в шортах” положительно связано с температурой воздуха.



Событие “проведение исследования” явно связана с предиктором “объем полученного финансирования”, однако эта связь может быть совсем непростой.




А что если хотим классификацию?

 $y = \{0, 1\}$

Допустим бинарная классификация



Отношение шансов



Шансы (odds) часто представляют в виде отношения шансов (odds ratio)

Если отношение шансов > 1 , то вероятность наступления события выше, чем вероятность того, что оно не произойдет.

Если отношение шансов < 1 , то наоборот.

Если можно оценить вероятность положительного события, то отношение шансов выглядит так:

$$odds = \frac{\pi}{1-\pi}$$

Отношение шансов варьируется от 0 до $+\infty$.

Попробуем сами $(-\infty; +\infty)$

① $p_i: -[\text{вероятности } m \cdot v, n \cdot v] \quad y_i = 1$
 $1 - p_i: -[] \quad y_i = 0$

② $\text{odds} = \frac{p_i}{1 - p_i} \quad [0; +\infty)$

③ $\text{logit} = \ln \left(\frac{p_i}{1 - p_i} \right) \quad (-\infty; +\infty)$



Логиты



Отношение шансов можно преобразовать в логиты(logit):

$$\ln(odds) = \ln\left(\frac{\pi}{1 - \pi}\right)$$

- Значения логитов – это трансформированные оценки вероятности события.
- Логиты варьируют от $-\infty$ до $+\infty$.
- Логиты симметричны относительно 0, т.е. $\ln(1)$.
- Для построения моделей в качестве зависимой переменной удобнее брать логиты.

Считаем вероятность


$$\ln\left(\frac{p_i}{1-p_i}\right) = xw \quad | \exp$$

$$\frac{p_i}{1-p_i} = e^{xw}$$


$$p_i = e^{xw} - p_i e^{xw}$$

$$p_i(1 + e^{xw}) = e^{xw}$$

$$p_i = \frac{e^{xw}}{1 + e^{xw}} = \frac{1}{e^{-xw} + 1} = \sigma(xw)$$



Как такое учить? BCE Loss


$$BCE = \frac{1}{N} \sum_{i=1}^N - [y_i \ln p_i + (1 - y_i) \cdot \ln(1 - p_i)]$$

$y_i = \{0, 1\}$


$$p_i \in [0, 1] \quad p_i = \sigma(x; w)$$

1) $y_i = 1; p_i = 1; BCE = 0$

2) $y_i = 1; p_i = 0; BCE = +\infty$

3) $y_i = 1; p_i = 0.5; BCE = 0.7$

Как такое учить? BCE Loss


$$\nabla_{\mathbf{w}} \text{BCE} = \boxed{\mathbf{X}^T \cdot (\mathbf{p} - \mathbf{y})}$$
$$\mathbf{p} = \sigma(\mathbf{X}\mathbf{w})$$


Качество классификации



Качество классификации. ROC кривая

$$TPR = \frac{TP}{TP + FN} = \text{recall}$$


$$FPR = \frac{FP}{FP + TN}$$



[рисуем свою ROC кривую](#)

Построение ROC кривой

		пороги						
y	g	0	0.2	0.4	0.6	0.8	1.	
1	0.8	1	1	1	1	1	0	
0	0.6	1	1	1	1	0	0	
1	0.4	1	1	1	0	0	0	
0	0.2	1	1	0	0	0	0	
TPR		1	1	1	0.5	0.5	0	
FPR		1	1	0.5	0.5	0	0	



$$TPR = \frac{TP}{TP + FN}$$

$$FPR = \frac{FP}{FP + TN}$$

$$ROC - AUC = 0.75$$